

TÍTOL: L'ÀLGEBRA LINEAL COM A MOTOR DE LA INTEL·LIGÈNCIA ARTIFICIAL

PORTADA (TÍTOL, NOM, COGNOM, GRUP, ETC.).

ABSTRACT (ÚLTIMA PART DEL TR).

ÍNDEX

INTRODUCCIÓ.....	2
MARC TEÒRIC.....	4
CAPÍTOL 1: FONAMENTS MATEMÀTICS.....	4
2.1.1. QUÈ ÉS L'ÀLGEBRA LINEAL.....	4
2.1.1.2. OPERACIONS BÀSIQUES DE VECTORS I MATRIUS.....	4
2.1.1.3. TRANSFORMACIONS LINEALS.....	7
2.1.1.4. VALORS I VECTORS PROPIS.....	8
CAPÍTOL 2: IA I APRENENTATGE AUTOMÀTIC.....	9
2.2.1 QUÈ SÓN EL MACHINE LEARNING I DEEP LEARNING.....	9
2.2.1.1 DIFERÈNCIES ENTRE MACHINE LEARNING I DEEP LEARNING.....	9
2.2.1.2 IMPORTÀNCIA DE LES DADES.....	10
2.2.2 QUIN TIPUS D'ALGORITMES D'APRENENTATGE HI HA?.....	11
2.2.2.1 APRENENTATGE SUPERVISAT.....	11
2.2.2.2 APRENENTATGE NO SUPERVISAT.....	12
2.2.2.3 APRENENTATGE PER REFORÇ.....	13
2.2.3 VISUALITZACIÓ I TRACTAMENT DE DADES.....	13
2.2.4 MÈTRiques PER AVALUAR ELS MODELS.....	14
2.2.5 GRÀFIQUES.....	15
2.2.6 LLENGUATGES DE PROGRAMACIÓ MÉS UTILITZATS EN ML.....	16
2.2.6.1 PYTHON I LES LLIBRERIES MÉS UTILITZADES EN ML.....	17
CAPÍTOL 3: US DE L'ÀLGEBRA LINEAL EN MACHINE LEARNING.....	17
2.3.1 FUNCIONAMENT D'UN DATASET COM A MATRIU.....	17
2.3.2 LA NORMALITZACIÓ DE DADES COM A TRANSFORMACIÓ LINEAL.....	18
2.3.3 EXEMPLES D'ÚS DE L'ÀLGEBRA LINEAL DINS DEL MACHINE LEARNING.....	19
2.3.3.1 UTILITAT DELS VECTORS EN LA PRESA DE DECISIONS DE L'ALGORITME KNN.....	19
2.3.3.2 EL PRODUCTE ESCALAR COM A EINA DE SIMILITUD.....	19
BIBLIOGRAFIA I WEBGRAFIA.....	21

INTRODUCCIÓ

1.1. PRESENTACIÓ TEMA TR

En l'actualitat, la intel·ligència artificial o IA rep un rol molt important i es pot dir que està present en pràcticament en una part de l'etapa acadèmica dels molts estudiants, però es percep sovint com una tecnologia màgica i incomprensible. No obstant això, la realitat és que no és màgia, sinó un sistema complex de matrius i vectors que estructuren i transformen dades.

Aquest estudi s'origina de la necessitat de desmitificar la intel·ligència artificial, per això mateix, aquest se centrarà en la columna vertebral darrere d'aquests sistemes: l'àlgebra lineal, conjuntament amb el machine learning.

1.2. PER QUÈ HE ESCOLLIT AQUEST TREBALL?

Aquesta elecció de tema és deguda a unes motivacions: En primer lloc, la profunda curiositat per entendre com pot ser que les mates que s'estudien a classe, amb sistemes complexos i abstractes, puguin ser el motor d'aquesta revolució tecnològica. En segon lloc, poder entendre conceptes fonamentals per a la carrera i millorar el nivell propi en el llenguatge de programació utilitzat per aquest treball, Python.

1.3. OBJECTIUS DEL TREBALL

Per aconseguir desmitificar el funcionament intern de la IA, s'estableixen els següents objectius:

- Poder comprendre i tenir la capacitat d'explicar els conceptes fonamentals de l'àlgebra lineal, així, poder construir una base en aquest camp per a anys següents.
- Entendre i demostrar com l'àlgebra lineal permet amb algorismes de Machine learning classificar dades
- Descobrir i Aplicar com una màquina pot donar respostes amb autonomia suficient processant una gran base de dades amb la qual se l'ha entrenat prèviament.
- Demostrar que el que es dona a classe, té una gran utilitat en diferents camps relacionats.

1.4. ABAST I LIMITACIONS

Aquesta investigació se centrarà sobretot en la part d'entrenament i representació de dades dins de l'aprenentatge automàtic o machine learning. Per poder garantir el nivell adequat en el temps que s'ha establert, s'han establert unes limitacions: s'exclourà el camp de Deep Learning dins de la part pràctica pel seu requisit de càlculs pràcticament infinits, per això mateix, el Deep Learning només s'abordarà en la part teòrica relacionant-ho amb el machine learning. La part pràctica es limitarà a bases de dades existents, ja que es necessitaran milers per poder entrenar a la màquina i no és realista poder aconseguir-ho.

1.5. MATERIAL I METODOLOGIA DE TREBALL

De cara als materials, s'utilitzarà una base de dades pública a internet, i programarà en Python amb diferents llibreries d'aquest. Respecte a la metodologia, encara no s'ha acabat de decidir quina, però possiblement serà la metodologia de recerca hipotètica-deductiva.

MARC TEÒRIC

CAPÍTOL 1: FONAMENTS MATEMÀTICS

2.1.1. QUÈ ÉS L'ÀLGEBRA LINEAL

L'àlgebra és la branca de les matemàtiques que estudia les operacions mitjançant nombres i variables, aquestes representades per símbols, per trobar les relacions que hi ha dins de l'operació.

D'altra banda, l'àlgebra lineal s'encarrega de l'estudi de conceptes com les matrius, els vectors, els espais vectorials i les equacions lineals. En aquesta branca, els conceptes predominen tant com els càlculs, ja que s'introdueix el pensament abstracte. Per aquest motiu, gran part de l'àlgebra lineal es pot interpretar geomètricament, cosa que ajuda a visualitzar i comprendre millor aquests conceptes.

L'àlgebra lineal es caracteritza per l'estudi d'estructures matemàtiques anomenades espais vectorials. Un espai vectorial és un conjunt de vectors en el qual es poden fer diferents operacions, per exemple, la suma de vectors i el producte d'un vector per un nombre real o complex.

Elements de l'àlgebra lineal

- **Vectors:** són elements que poden representar magnitud i direcció. Gràficament, es poden interpretar com a segments amb una direcció, un sentit i un mòdul.
- **Matrius:** són taules de dues dimensions formades per nombres organitzats en files i columnes. Permeten representar sistemes d'equacions i transformacions lineals.

Aquesta branca és una eina imprescindible en camps com la física, l'enginyeria o l'arquitectura, entre molts d'altres.

2.1.1.2. OPERACIONS BÀSIQUES DE VECTORS I Matrius

Les operacions de vectors i matrius apareixen constantment dins el funcionament del Machine Learning.

Operacions de vectors:

Les operacions amb vectors més importants són:

- **Suma:** combinació de dos vectors per a aconseguir un vector resultant; es realitza sumant les mateixes components dels dos vectors.

$$\vec{A} + \vec{B} = (ax + bx, ay + by)$$




Figura 1.1. Gràfic suma de Vectors.

FONT: <https://www.neurochispas.com/fisica/operaciones-con-vectores-ejercicios/>

- **Resta:** és la diferència entre 2 vectors, funciona igual que la suma.

$$\vec{A} - \vec{B} = (ax - bx, ay - by)$$




Figura 1.2. Gràfic resta de vectors.

FONT: <https://miprofe.com/resta-de-vectores/>

- **Producte per un escalar:** multiplica el vector per un nombre.

$$k \cdot \vec{A} = (k \cdot ax, k \cdot ay)$$

$$2 \cdot (2, 1) = (4, 2)$$




Figura 1.3. Gràfic producte per un escalar.

FONT: <https://www.fisicapractica.com/producto-escalar-vector>

- **Producte escalar entre dos vectors:** dona un únic número i permet mesurar quant s'assemblen o s'alineen dos vectors.

$$A \cdot B = (ax \cdot bx) + (ay \cdot by) = ||A|| ||B|| \cos \theta$$




Figura 1.4. Gràfic producte escalar.

FONT: <https://fisicabachillerato.netlify.app/vectores-prodescalar>

Operacions de matrius:

Amb les matrius es poden fer les mateixes operacions: suma, resta i multiplicació.

- **Suma i resta:** es realitzen operant els components, sumant o restant els elements en la mateixa columna i fila de les dues matrius.

$$A = \begin{pmatrix} 2 & 0 & 1 \\ 3 & 0 & 0 \\ 5 & 1 & 1 \end{pmatrix} \quad B = \begin{pmatrix} 1 & 0 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 0 \end{pmatrix}$$

$$A + B = \begin{pmatrix} 2+1 & 0+0 & 1+1 \\ 3+1 & 0+2 & 0+1 \\ 5+1 & 1+1 & 1+0 \end{pmatrix} = \begin{pmatrix} 3 & 0 & 2 \\ 4 & 2 & 1 \\ 6 & 2 & 1 \end{pmatrix} \quad A - B = \begin{pmatrix} 2-1 & 0-0 & 1-1 \\ 3-1 & 0-2 & 0-1 \\ 5-1 & 1-1 & 1-0 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 2 & -2 & -1 \\ 4 & 0 & 1 \end{pmatrix}$$

Figura 1.5. Suma i resta de matrius.

FONT: <https://www.superprof.es/diccionario/matematicas/algebralineal/operaciones-matrices.html>

- **Multiplicació de matrius:** té unes regles pròpies; per poder multiplicar dues matrius, el nombre de columnes de la primera ha de ser igual al nombre de files de la segona. Es realitza sumant el resultat del producte de les files per les columnes, creant una nova matriu que combina els elements de les altres dues.

$$A \cdot B = \begin{pmatrix} 2 & 0 & 1 \\ 3 & 0 & 0 \\ 5 & 1 & 1 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 2 \cdot 1 + 0 \cdot 1 + 1 \cdot 1 & 2 \cdot 0 + 0 \cdot 2 + 1 \cdot 1 & 2 \cdot 1 + 0 \cdot 1 + 1 \cdot 0 \\ 3 \cdot 1 + 0 \cdot 1 + 0 \cdot 1 & 3 \cdot 0 + 0 \cdot 2 + 0 \cdot 1 & 3 \cdot 1 + 0 \cdot 1 + 0 \cdot 0 \\ 5 \cdot 1 + 1 \cdot 1 + 1 \cdot 1 & 5 \cdot 0 + 1 \cdot 2 + 1 \cdot 1 & 5 \cdot 1 + 1 \cdot 1 + 1 \cdot 0 \end{pmatrix} = \begin{pmatrix} 3 & 1 & 2 \\ 3 & 0 & 3 \\ 7 & 3 & 6 \end{pmatrix}$$

Figura 1.6. Multiplicació de matrius.

FONT: <https://www.superprof.es/diccionario/matematicas/algebralineal/operaciones-matrices.html>

- **Transposada d'una matriu:** consisteix a intercanviar les seves files per les seves columnes.

$$A = \begin{pmatrix} 2 & 3 & 0 \\ 1 & 2 & 0 \\ 3 & 5 & 6 \end{pmatrix} \quad A^t = \begin{pmatrix} 2 & 1 & 3 \\ 3 & 2 & 5 \\ 0 & 0 & 6 \end{pmatrix}$$

Figura 1.7. Transposada d'una matriu.

FONT: <https://www.superprof.es/diccionario/matematicas/algebralineal/matriz-traspuesta.html>

- **Matriu inversa:** Donada una matriu quadrada A , la seva inversa (A^{-1}) multiplicada per l'original donarà com a resultat la matriu I o identitat, que és una matriu que on tot són 0 menys la diagonal, que és 1.

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \quad A^{-1} = \frac{1}{|A|} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

Figura 1.8. Matriu inversa.

FONT: <https://www.neurochispas.com/wiki/matriz-inversa-de-matriz-2x2-ejercicios-resueltos/>

2.1.1.3. TRANSFORMACIONS LINEALS

Una transformació lineal és una funció $L: V \rightarrow W$ entre dos espais vectorials, V i W , la qual, donats qualssevol vectors $u, v \in V$ i un escalar c , compleix aquestes dues condicions:

1. $L(u + v) = L(u) + L(v)$
2. $L(cu) = cL(u)$

Aquests dos requisits són equivalents a la condició única que per a qualsevol parella de vectors u, v i escalars c, d , es compleixi que:

$$L(cu + dv) = cL(u) + dL(v)$$

En els casos on l'espai vectorial de destinació és el mateix que l'espai d'origen, és a dir, $V = W$, la transformació s'anomena habitualment **operador lineal**.

D'altra banda, és un principi fonamental que tota transformació lineal entre espais vectorials de dimensió finita pot ser representada mitjançant una matriu. Especialment, si A és una matriu, aleshores la funció $f(x) = Ax$ constitueix una transformació lineal.

2.1.1.4. VALORS I VECTORS PROPIS

Quan s'aplica una transformació lineal (representada per la matriu A) a un espai, aquest es va deformant; normalment, els vectors canvien de direcció i longitud després de ser transformats.

No obstant això, existeixen uns vectors que, o bé no són afectats per la transformació, o acaben multiplicats per un escalar i, per tant, la seva direcció no varia. Aquests vectors s'anomenen “**vectors propis**” o “**eigenvectors**”.

El factor escalar pel qual s'ha multiplicat el vector propi rep el nom de “**valor propi**” o “**eigenvalue**”, representat per lambda (λ).

La relació d'aquests vectors s'expressa amb la següent equació:

$$A x = \lambda x$$

CAPÍTOL 2: IA I APRENTATGE AUTOMÀTIC

2.2.1 QUÈ SÓN EL MACHINE LEARNING I DEEP LEARNING

El Machine Learning (ML) o aprenentatge automàtic és una branca de la intel·ligència artificial on les màquines aprenen patrons a partir de dades per realitzar prediccions futures, sense haver estat programades per a la tasca sol·licitada. No es donen a la màquina unes regles fixes, sinó que se li donen les dades i les eines amb l'objectiu que pugui trobar ella mateixa les seves normes.

Per exemple, si un enginyer vol fer que la màquina classifiqui imatges de cotxes depenent de les seves característiques, el que ha de fer l'enginyer inicialment és definir les característiques que la màquina haurà d'identificar; per exemple, l'algoritme ha de buscar cercles que semblin rodes. Després, l'algoritme ha d'aprendre a classificar imatges depenent d'aquestes característiques.

En canvi, el Deep Learning (DL) o aprenentatge profund és una subcategoria avançada del Machine Learning que utilitza xarxes neuronals amb gran profunditat, que imiten el funcionament del cervell humà amb diverses capes de processament connectades. Això permet processar dades complexes, com imatges o àudio.

Continuant amb l'exemple del cotxe, en aquest cas no es defineixen característiques a mà. Se li introdueixen moltes fotos de cotxes directament, que l'algoritme anirà processant moltes vegades per acabar concluint si l'objecte és un cotxe o no.

2.2.1.1 DIFERÈNCIES ENTRE MACHINE LEARNING I DEEP LEARNING

Característiques	Machine learning	Deep learning
Algoritmes	Arbres de decisió, regressió, K-Nearest Neighbors (KNN).	Xarxes neuronals profundes (CNN, RNN, Transformers).
Dades	Dades estructurades (taules numèriques, base de dades, etc).	Dades no estructurades (imatges, àudio, text).

Intervenció humana	Requereix intervenció humana per extreure les característiques del DataSet.	Extracció automàtica de les característiques.
Recursos i precisió	Pot executar-se en CPUs estàndard.	Requereix més recursos, com GPUs més potents.
Aplicacions	Detecció d'estafes, prediccions, classificació, etc.	Reconeixement facial, chat GPT, conducció autònoma, etc.

2.2.1.2 IMPORTÀNCIA DE LES DADES

Les dades són l'element més important de qualsevol sistema de machine learning. No obstant això, no n'hi ha prou amb tenir-ne una gran quantitat: la qualitat d'aquestes és igual d'important. La qualitat de les dades mesura fins a quin punt un conjunt de dades compleix criteris com l'exactitud, la integritat, la validesa, la coherència, la unicitat i l'actualitat.

Quan la qualitat no és suficient, les conseqüències poden ser molt greus. Si l'algoritme aprèn a predir o classificar a partir de dades errònies, els resultats que produirà també seran inexactes. Aquest principi es resumeix amb el concepte garbage in, garbage out: si l'entrada és dolenta, la sortida també ho serà.

Per avaluar si les dades són prou bones, s'utilitzen diferents criteris. Els més rellevants per al machine learning són els següents:

- **Integritat:** fa referència a la quantitat de dades completes i utilitzables. Un alt percentatge de valors buits pot donar lloc a una anàlisi enganyosa si les dades no representen una mostra típica.
- **Unicitat:** representa la quantitat de dades duplicades en un conjunt de dades. Les duplicacions alteren els patrons que el model ha d'aprendre.
- **Precisió:** fa referència a la correcció dels valors de les dades basant-se en una font fiable acordada.
- **Coherència:** avalua bases de dades de dos conjunts de dades diferents per comprovar que les tendències i el comportament de les dades siguin consistents.

2.2.2 QUIN TIPUS D'ALGORITMES D'APRENTATGE HI HA?

Els algorismes de machine learning són els procediments i la lògica matemàtica amb què una màquina pot aprendre a identificar patrons de dades i, així, poder fer prediccions amb altres dades.

Existeixen 3 tipus d'algorismes d'aprenentatge automàtic:

- **Supervisat:** amb el model supervisat, la màquina aprèn per l'exemple. A partir de dades amb les respostes correctes amb què l'operador l'entrena, la màquina aprèn els patrons que les relacionen i els aplica en futures dades.
- **No supervisat:** dins del model no supervisat, a diferència del model supervisat, la màquina no rep dades etiquetades amb la resposta correcta, sinó que haurà d'aprendre els patrons per si mateixa sense tenir-ne coneixement.
- **Per reforç:** és el model tradicional de prova i error, on la màquina explora el seu entorn i les diferents possibilitats. Depenent de si la decisió és a prop de l'objectiu o no, rep una "recompensa" o "penalització", i aprèn d'experiències passades per no rebre aquestes "penalitzacions".

2.2.2.1 APRENTATGE SUPERVISAT

L'aprenentatge supervisat (Supervised Learning) és el model d'aprenentatge automàtic més utilitzat dins la indústria. Consisteix a entrenar un algorisme proporcionant-li un conjunt de dades on cada element d'entrada (vector de característiques) té la seva resposta correcta (etiqueta o target). L'objectiu del model és deduir la funció que relaciona les entrades amb les sortides, minimitzant el marge d'error, per poder predir amb precisió les etiquetes o respostes de noves dades futures. Aquest tipus d'aprenentatge es divideix en dos subtipus segons les característiques de les dades que es vol predir:

1. **Classificació:** els problemes de classificació neixen quan l'algorisme ha d'assignar cada dada a una classe o grup específic (per exemple: "aprobat o suspès", "maligne o benigne"). Alguns dels models més coneguts són:
 - **Regressió Logística (LogisticRegression):** tot i que el seu nom diu el contrari, és un model de classificació. Utilitza la funció sigmoide per transformar el resultat d'una combinació lineal en un valor de probabilitat entre 0 i 1. Algunes utilitats poden ser els filtres de correu brossa, on la màquina haurà de dir, depenent d'alguns patrons, si el correu és brossa o no.

- **Arbres de Decisió (DecisionTreeClassifier):** Crea un arbre invertit per realitzar prediccions, iniciant a la part superior amb una pregunta sobre característiques importants sobre aquestes dades i després s'anirà ramificant, descartant possibles respostes, fins a arribar a una decisió final. Una gran utilitat per a aquest algoritme pot ser l'avaluació de riscos financers.
 - **Màquines de Vectors de Suport (SVM - Support Vector Machines):** Un dels models més precisos. L'algoritme busca l'hiperplà (una línia recta en un espai 2D o un pla en un espai 3D) que pugui separar els tipus de dades amb el marge més gran possible. S'utilitza bastant en la bioinformàtica per classificar gens i proteïnes, per exemple.
2. **Regressió:** s'utilitza quan la variable que s'haurà de predir és numèrica i contínua, és a dir, un valor dins d'un rang quantitatiu. Algunes aplicacions poden ser en projeccions d'ingressos per vendes o planificació financera. Alguns models de regressió són:
- **Regressió Lineal:** l'algoritme busca la línia recta. Aquest model tracta de trobar la relació que hi ha entre les dues variables, una dependent i l'altra independent, minimitzant la suma dels errors quadràtics. S'utilitza per fer prediccions de preus d'immobles basant-se en l'espai o la ubicació de l'immoble.
 - **Regressió Polinòmica:** variant que permet trobar relacions no lineals elevant les variables d'entrada (independents) a potències superiors. Es pot veure utilitzada per fer modelatges de taxes de creixement de població.

2.2.2.2 APRENTATGE NO SUPERVISAT

L'aprenentatge no supervisat o unsupervised learning utilitza algorismes de machine learning per agrupar conjunts de dades sense estar etiquetades, descobrint patrons per si mateix. A diferència del model supervisat, la màquina no té cap resposta correcta etiquetada, sinó que haurà de trobar-les.

El principal objectiu d'aquest model és aconseguir coneixement de grans quantitats de dades noves, on l'algoritme determina què és útil dins del conjunt de dades. La seva capacitat el converteix en una eina important quan no se saben els patrons de les dades.

Dins de l'aprenentatge no supervisat hi ha diferents subtipus:

Clustering: consisteix a agrupar dades en grups, anomenats clústers, de manera que les dades dins d'un mateix grup siguin similars entre elles i diferents de les d'altres grups. L'algoritme més utilitzat és:

- **K-Means:** assigna cada punt de dades a un dels clústers en funció de la distància mínima entre el punt i el centre del clúster, ajustant els centres fins a aconseguir una configuració òptima que minimitzi les diferències dins

de cada clúster. Una aplicació típica és la separació de clients en clústers depenent de les seves variables analitzades en màrqueting.

Reducció de dimensionalitat: tot i que en aprenentatge supervisat també existeix la reducció de dimensionalitat, no és tan freqüent el seu ús, se sol utilitzar molt més en el model no supervisat. Permet simplificar un conjunt de dades reduint el nombre de variables i mantenint la informació més rellevant. L'algoritme principal és:

- **Anàlisi de Components Principals (PCA):** s'utilitza per reduir el nombre de variables en un conjunt de dades mentre es manté la informació més rellevant; això ajuda a simplificar els models i el processament.

2.2.2.3 APRENTATGE PER REFORÇ

L'aprenentatge per reforç o reinforcement learning, a diferència del supervisat i el no supervisat, no funciona per anàlisi de bases de dades fixes, sinó per prova i error; l'algoritme, anomenat “agent”, interactua amb un entorn dinàmic, no fix. A mesura que pren decisions i executa accions, l'entorn li retorna una “recompensa” o “penalització”, depenent de si s'apropa a l'objectiu o no. L'objectiu de la màquina és aconseguir acumular la màxima recompensa, aprenent de les experiències passades per crear la millor estratègia possible. Aquest tipus d'aprenentatge és la tecnologia principal darrere de la robòtica avançada, la conducció de vehicles autònoms i les intel·ligències artificials entrenades per dominar jocs complexos com els escacs.

L'algoritme clàssic dins de l'aprenentatge per reforç és:

Q-Learning: el principal objectiu del Q-learning és descobrir la millor estratègia per maximitzar la “recompensa”; utilitza una Q-table per guardar els valors d'utilitat on associa les accions possibles, on cada valor significa el guany de “recompensa” que tindrà amb cada acció possible, i l'agent fa servir aquests valors per seleccionar les millors opcions que té.

2.2.3 VISUALITZACIÓ I TRACTAMENT DE DADES

Dins del camp de l'aprenentatge automàtic, les dades rarament es troben llestes per a ser utilitzades per un algorisme. El tractament i la visualització de dades són fases molt importants que garanteixen una estructura coherent i que l'algorisme no tingui obstacles.

1. **Visualització de dades:** consisteix a mostrar gràficament les relacions numèriques i estructurals de les dades mitjançant diagrames. Alguns dels usos més freqüents són:

- **Identificació de tendències i distribucions:** permet observar visualment si les dades tenen relacions lineals o corbes evidents.
 - **Detecció de valors anòmals (outliers):** ajuda a localitzar punts de dades anòmals o erronis que desvien l'aprenentatge del model.
2. **Tractament de dades (preprocessing):** el tractament s'encarrega de netejar i transformar la informació. Les operacions més importants són:
- **Gestió de valors buits (missing Data):** si la base de dades conté buits, els càlculs fallaran. Aquest procés consisteix a eliminar aquestes files o substituir-los de manera lògica fent la mitjana o la mediana del grup
 - **Normalització (Feature Scaling):** és l'operació més important i crítica. Consisteix a escalar les dades entre el 0 i l'1 per aconseguir una millor precisió a l'hora de fer les prediccions. Si se salta aquest pas, en algorismes geomètrics com KNN, que calculen distàncies entre vectors on les dades poden arribar a ser de milers, les prediccions poden estar extremadament desviades.
 - **Codificació de variables categòriques (encoding):** els models d'intel·ligència artificial només operen amb matrius i vectors numèrics. Per tant, les columnes que contenen text, per exemple maligne/benigne, s'han de transformar en valors numèrics, com el 0 i l'1.

2.2.4 MÈTRIQUES PER AVALUAR ELS MODELS

Després d'haver entrenat un model, s'ha de mesurar el seu rendiment matemàticament i de forma objectiva. Com que cada tipus d'algoritme funciona de manera diferent, els criteris de mesura es divideixen depenent del tipus d'aprenentatge:

1. Mètriques per avaluar els models d'aprenentatge supervisat

a. Models de Classificació

- Matriu de Confusió (confusion Matrix):** és una taula bidimensional que separa els encerts i errors de l'algoritme. Organitza els resultats en 4 tipus: Verdaders Positius (VP), Verdaders Negatius (VN), Falsos Positius (FP) i Falsos Negatius (FN).
- Exactitud (accuracy):** És la representació del total de prediccions correctes respecte als casos que s'han analitzat.

Es calcula mitjançant una fórmula:

$$Exactitud = \frac{VP + VN}{VP + VN + FP + FN}$$

b. Models de Regressió

- i. **Error Quadràtic Mitjà (Mean Squared Error):** calcula la mitjana dels errors elevats al quadrat. Aquesta és una eina excel·lent per veure si l'algoritme comet errors crítics, ja que penalitza molt els grans desviaments.

2. Mètriques per avaluar els models d'aprenentatge no supervisat

- i. **Coefficient de Silueta (silhouette Score):** mesura el grau de separació i cohesió dels clústers dins de l'espai vectorial. El seu valor pot estar entre -1 i 1. Un resultat proper a 1 indica que els elements d'un mateix clúster estan molt junts i que els diferents clústers estan ben distanciats entre ells, un resultat nul significa que les dades es troben entre 2 clústers, i un resultat a prop de -1 significa que els elements s'han assignat al clúster incorrecte i estan més a prop d'un altre clúster veí.

3. Mètriques per avaluar els models d'aprenentatge per reforç

- i. **Recompensa Total per Episodi (episode Reward):** és la suma de recompenses i penalitzacions que l'agent acumula en un episodi. Si l'algoritme està aprenent correctament, la gràfica d'aquesta mètrica ha de mostrar una corba ascendent al llarg dels intents fins que s'estabilitzi.

2.2.5 GRÀFIQUES

Els gràfics són una representació visual de dades per facilitar-ne la interpretació. En machine learning, són una eina fonamental per visualitzar els resultats; així es pot detectar més fàcilment si l'algoritme està encertant o no.

En machine learning existeixen gràfics per a dos usos diferents:

- Anàlisi de dades
- Avaluació de models

Els tipus de gràfics més utilitzats en l'anàlisi de dades són:

- **Gràfic de línies**
- **Gràfic de barres**
- **Gràfic de dispersió**

Els tipus de gràfics més utilitzats en l'avaluació de dades són:

Matriz de confusión: Modelo SVM


	ira	tristeza	asco	felicidad	sorpresa	miedo
ira	37	0	1	2	5	0
tristeza	0	59	3	0	0	4
asco	0	3	47	4	4	0
felicidad	2	0	3	45	3	0
sorpresa	9	0	3	7	45	0
miedo	0	1	1	1	0	48
	ira	tristeza	asco	felicidad	sorpresa	miedo
	predicción					

Matriu de confusió

Una matriu de confusió és una taula quadrada de dimensions $n \cdot n$ que relaciona les etiquetes reals d'un dataset, les quals són les files, i les prediccions de l'algorisme, que són les columnes. L'èxit del model es pot veure en la diagonal principal, ja que qualsevol valor fora d'aquesta línia indica un error on el sistema s'ha confós.

Figura 2.4. Matriu de confusió.

FONT: <https://www.researchgate.net>



Corba ROC

La corba ROC és un gràfic que avalua el rendiment relacionant els veritables positius amb els falsos positius. Quan més s'apropa la corba de la diagonal aleatòria i s'apropa a la cantonada superior esquerra, més precís és el model, per saber el coeficient, s'ha de calcular l'àrea per sota la corba (AUC), com més s'apropi l'àrea a 1, més correcte és el model.

Figura 2.5. Corba ROC.

FONT: https://ca.wikipedia.org/wiki/Corba_caracter%C3%ADstica_de_funcionament_del_receptor

2.2.6 LENGUATGES DE PROGRAMACIÓ MÉS UTILITZATS EN ML

Dins de la programació orientada a machine learning es fan servir diferents llenguatges de programació depenent de la tasca i l'estructura del sistema. Els llenguatges de programació més utilitzats dins el sector són:

- **Python:** és l'estàndard de la indústria. El seu èxit es deu a la similitud amb el llenguatge humà, fet que el fa bastant més fàcil de dominar que els altres llenguatges de programació. Gràcies a la seva sintaxi senzilla, els programadors es poden centrar en la lògica dels algorismes en lloc de

perdre el temps amb la complexitat del codi mateix. Com que és un llenguatge de codi obert, compta amb una gran quantitat de llibreries especialitzades en diversos camps.

- **R:** és un llenguatge especialitzat en l'estadística i visualització de dades. S'utilitza bastant en l'entorn acadèmic i de recerca de dades complexes.
- **C++:** es caracteritza per la seva velocitat de processament extrema i per una gestió de memòria eficient. Dins del Machine Learning s'utilitza sobretot per programar el motor intern de la intel·ligència artificial en entorns que necessiten la seva gran velocitat, com pot ser un videojoc modern.

2.2.6.1 PYTHON I LES LLIBRERIES MÉS UTILITZADES EN ML

Python és un dels llenguatges més utilitzats en machine learning per la seva gran quantitat de llibreries exclusives del sector. Per poder fer servir els models de machine learning, les llibreries més utilitzades són:

- **Pandas:** l'eina amb la qual s'analitzen i es tracten les dades. Introdueix el DataFrame, que és l'equivalent a una taula amb files i columnes. S'utilitza sobretot per a poder identificar i gestionar dades buides o errònies i preparar la informació abans d'entrenar el model.
- **NumPy:** està dissenyada per gestionar estructures algebraïques com vectors o matrius multidimensionals de manera eficient i ràpida.
- **Scikit-Learn (sklearn):** és la llibreria principal de l'aprenentatge automàtic tradicional. Inclou la majoria d'algorismes per poder ser entrenats. A més, conté altres mòduls per poder avaluar la precisió del model i també té una àmplia gamma de bases de dades amb l'objectiu d'importar-les i utilitzar-les.
- **Matplotlib:** és l'estàndard per a la visualització de dades. Permet transformar vectors numèrics en representacions visuals (gràfics de dispersió o diagrames de barres) per facilitar la interpretació de les dades.

CAPÍTOL 3: US DE L'ÀLGEBRA LINEAL EN MACHINE LEARNING

2.3.1 FUNCIONAMENT D'UN DATASET COM A MATRIU.

Un dataset està organitzat per files i columnes: les files són elements del conjunt que actuen com a vectors unidimensionals i les columnes són característiques d'aquest element, és a dir, defineixen les dimensions de l'espai vectorial. Però, per a la màquina, la informació està representada com una matriu, i l'algoritme extreu les dades del conjunt i hi opera. Per exemple, si es disposa d'un dataset organitzat de la manera següent:

Vehicle	Pes (kg)	Potència (CV)	Edat (Anys)	Preu (€)
Cotxe 1	1.200	110	5	12.000
Cotxe 2	1.650	190	2	28.000
Cotxe 3	950	75	12	3.500

Taula 3.1. Exemple dataset

Quan la informació ja ha estat processada i preparada pel model, l'algoritme extreu només les dades numèriques, transformant la taula en la següent matriu algebraica:

$$X = \begin{bmatrix} 1200 & 110 & 5 & 12000 \\ 1650 & 190 & 2 & 28000 \\ 950 & 75 & 12 & 3500 \end{bmatrix}$$

Figura 3.1. Exemple matriu

2.3.2 LA NORMALITZACIÓ DE DADES COM A TRANSFORMACIÓ LINEAL

Les dades d'un conjunt de dades normalment no comparteixen la mateixa escala. Per exemple, en un conjunt de dades de cotxes, el pes pot estar entre 1.000 i 2.000 quilograms, mentre que l'edat del vehicle oscil·la entre valors d'un o dos dígit. Si s'utilitzen aquestes dades sense tractar-les prèviament, els valors grans dominaran als més petits. Com s'ha definit en els anteriors apartats, una transformació lineal és una funció que opera sobre vectors mantenint les seves relacions proporcionals. La normalització és exactament això: una transformació lineal que s'aplica a tots els vectors del conjunt de dades per escalar els seus valors entre 0 i 1.

Utilitza la fórmula següent:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

La fórmula resta el valor mínim de la característica a cada dada i ho divideix pel rang total dels valors. Per exemple, si el pes mínim del dataset és 800 kg i el màxim és 2000 kg, un cotxe de 1500 kg es transformaria de la manera següent:

$$x' = \frac{1500 - 800}{2000 - 800} = \frac{700}{1200} = 0.58$$

El valor ja estarà escalat entre 0 i 1.

2.3.3 EXEMPLES D'ÚS DE L'ÀLGEBRA LINEAL DINS DEL MACHINE LEARNING

2.3.3.1 UTILITAT DELS VECTORS EN LA PRESA DE DECISIONS DE L'ALGORITME KNN

En un conjunt de dades bidimensional, les dades s'ubiquen com a punts en un espai geomètric. Quan el model rep una dada nova, l'algoritme KNN mesura la seva similitud calculant la distància entre el vector de la dada nova i els vectors de les dades que ja coneix. Per fer aquest càlcul, la màquina executa una resta de vectors, que dona com a resultat un vector A que uneix els dos punts en l'espai. Per poder saber la distància entre els punts, s'ha d'obtenir el mòdul del vector A; la fórmula del mòdul és:

$$|A| = \sqrt{A_x^2 + A_y^2}$$

El valor numèric donat és la distància algebraica entre els dos punts. L'algoritme KNN repeteix aquest procediment de forma massiva amb tots els vectors que pertanyen al dataset i ordena els resultats de menor a major. Finalment, decideix per majoria estadística l'etiqueta corresponent a la nova dada, basant-se en els seus veïns més propers.

2.3.3.2 EL PRODUCTE ESCALAR COM A EINA DE SIMILITUD

Com s'ha definit anteriorment, el producte escalar opera amb dos vectors de la mateixa dimensió i dona un escalar. Dins del Machine Learning, aquesta operació és una de les mètriques per avaluar la similitud entre dos punts de dades. La fórmula del producte escalar per mesurar semblances és la següent:

$$u \cdot v = ||u|| ||v|| \cos \theta$$

Aquesta equació demostra que el resultat depèn de l'angle θ que formen els dos vectors. Quan s'utilitza el producte escalar de dos vectors, l'algoritme interpreta el resultat de diferents maneres depenent de la relació dels vectors:

- **Vectors alineats:** quan l'angle és proper a 0° , el cosinus s'aproparà a 1; això provoca que el producte escalar sigui alt i positiu, fet que indica que les dues dades tenen una alta similitud.
- **Vectors ortogonals:** quan l'angle és igual a 90° , el cosinus serà 0, fet que provoca que el producte escalar sigui nul. Això significa que no hi ha cap relació entre les dues dades.

- **Vectors oposats:** quan l'angle és de 180° , el cosinus tendeix a -1 , assenyalant que els patrons són completament contraris.

No obstant això, hi ha un problema: el producte escalar també depèn del mòdul dels vectors. Dues dades poden ser molt similars en direcció, però tenir mòduls molt diferents, cosa que pot distorsionar el resultat. Per aïllar únicament l'angle, s'utilitza la similitud del cosinus:

$$\cos \theta = \frac{u \cdot v}{||u|| ||v||}$$

Aquesta tècnica normalitza el resultat entre -1 i 1 , sense importar el mòdul dels vectors. En conclusió, molts dels algorismes que mesuren la similitud comparen dues dades per prendre una decisió amb aquesta fórmula algebraica.

BIBLIOGRAFIA I WEBGRAFIA

2.1.1. QUÈ ÉS L'ÀLGEBRA LINEAL?

- Superprof: Álgebra lineal.
<https://www.superprof.es/apuntes/escolar/matematicas/algebralineal/>

2.1.1.2. OPERACIONS BÀSIQUES DE VECTORS I MATRIUS

- Rodó, P. (2019). *Operaciones con matrices: Qué son y cómo realizarlas*. Economipedia.
<https://economipedia.com/definiciones/operaciones-con-matrices.html>
- Rodó, P. (2022). *Operaciones con Vectores: Qué son y cómo se utilizan en matemáticas*. Economipedia.
<https://economipedia.com/definiciones/operaciones-con-vectores.html>
- Superprof: Operaciones con matrices.
<https://www.superprof.es/diccionario/matematicas/algebralineal/operaciones-matrices.html>

2.1.1.3. TRANSFORMACIONS LINEALS

- [Rowland, Todd and Weisstein, Eric W.](#) "Linear Transformation." From [MathWorld](#)--A Wolfram Resource.
<https://mathworld.wolfram.com/LinearTransformation.html>
- *Valor propi, vector propi i espai propi*. Viquipèdia.
https://ca.wikipedia.org/wiki/Valor_propi,_vector_propi_i_espai_propi

2.1.1.4. VALORS I VECTORS PROPIS

- [Weisstein, Eric W.](#) "Eigenvalue." From [MathWorld](#)--A Wolfram Resource.
<https://mathworld.wolfram.com/Eigenvalue.html>
- [Weisstein, Eric W.](#) "Eigenvector." From [MathWorld](#)--A Wolfram Resource.
<https://mathworld.wolfram.com/Eigenvector.html>

2.2.1.3. IMPORTÀNCIA DE LES DADES

- IBM: ¿Qué es la calidad de datos?.
<https://www.ibm.com/es-es/think/topics/data-quality>

2.2.2. QUIN TIPUS D'ALGORITMES D'APRENTATGE HI HA?

- [Dave Bergmann](#). IBM: ¿Qué son los algoritmos de machine learning?.
<https://www.ibm.com/es-es/think/topics/machine-learning-algorithms>

2.2.2.1. APRENTATGE SUPERVISAT

- [Ivan Belcic](#). IBM: What is Classification in Machine Learning?.
<https://www.ibm.com/think/topics/classification-machine-learning>

- [Ivan Belcic , Cole Stryker](https://www.ibm.com/think/topics/supervised-learning). IBM: What is Supervised Learning?
<https://www.ibm.com/think/topics/supervised-learning>

2.2.2.2. APRENTATGE NO SUPERVISAT

- IBM: *What is Unsupervised Learning?*
<https://www.ibm.com/think/topics/unsupervised-learning>
- IBM: *Supervised vs. Unsupervised Learning: What's the Difference?*
<https://www.ibm.com/think/topics/supervised-vs-unsupervised-learning>
- delatorre.ai: *Aprenentatge no supervisat (Unsupervised Learning)*
<https://delatorre.ai/aprenentatge-no-supervisat-unsupervised-learning/>

2.2.2.3. APRENTATGE PER REFORÇ

- AWS: ¿Qué es el aprendizaje por refuerzo?
<https://aws.amazon.com/es/what-is/reinforcement-learning/>
- Fundación innovación bankinter: Q-learning: el algoritmo del aprendizaje por refuerzo
<https://www.fundacionbankinter.org/noticias/q-learning/>

2.2.3. COM VISUALITZAR I TRACTAR LES DADES?

- IBM: What is Data Preprocessing?
<https://www.ibm.com/think/topics/data-preprocessing>
- *Python Data Science Handbook by Jake VanderPlas* - Introducing Scikit-Learn
<https://jakevdp.github.io/PythonDataScienceHandbook/05.02-introducing-scikit-learn.html>

2.2.4. MÈTRIQUES PER AVALUAR ELS MODELS

- Google Developers. *Machine learning crash course: Classification Metrics*. Google Machine Learning Guides.
<https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall>
- IBM. *What is a Confusion Matrix and how to interpret it?*.
<https://www.ibm.com/think/topics/confusion-matrix>
- Scikit-learn developers. *Clustering*.
<https://scikit-learn.org/stable/modules/clustering.html>
- ScienceDirect. (2024). *Silhouette Coefficient: Overview, definition and practical applications in clustering*. Computer Science Topics.

<https://www.sciencedirect.com/topics/computer-science/silhouette-coefficient>

- StudySmarter. (2023). *Reward Shaping and Episode Rewards in Artificial Intelligence Engineering*. StudySmarter Explanations.
<https://www.studysmarter.co.uk/explanations/engineering/artificial-intelligence-engineering/reward-shaping/>

2.2.5. GRÀFIQUES

- LinkedIn-LinkedIn Collective. (2024, 12 de febrer). *¿Cuáles son las mejores visualizaciones para mostrar el rendimiento del aprendizaje automático?*
<https://es.linkedin.com/advice/1/what-best-visualizations-showing-machine-learning-pve3c?lang=es>
- ID Digital School. (2023, 22 de novembre). *Tipos de gráficos para Data Science y Data Analytics: guía práctica*.
<https://iddigitalschool.com/bootcamps/tipos-de-graficos-para-data-science-y-data-analytics-guia-practica/>

2.2.6. LENGUATGES DE PROGRAMACIÓ MÉS UTILITZATS EN MACHINE LEARNING

- CampusMVP. (2023, 10 de gener). *Los 4 mejores lenguajes de programación para Inteligencia Artificial & Machine Learning*. Recursos TIC.
<https://www.campusmvp.es/recursos/post/los-4-mejores-lenguajes-de-programacion-para-inteligencia-artificial-machine-learning.aspx>
- Intecssa. (2024, 15 de març). *Los lenguajes de programación más efectivos para inteligencia artificial*. Instituto de Tecnologías Sociales y de la Salud.
<https://intecssa.com/los-lenguajes-de-programacion-mas-efectivos-para-inteligencia-artificial/>

2.2.6.1. PYTHON I LES LLIBRERIES MÉS UTILITZADES EN MACHINE LEARNING

- Datos.gob.es. (2023, 27 d'abril). *10 librerías populares de análisis de datos y machine learning*. Portal de Datos Abiertos del Gobierno de España.
<https://datos.gob.es/es/blog/10-librerias-populares-de-analisis-de-datos-y-machine-learning>
- IA Solver. (2024, 18 de setembre). *6 librerías de Python para Machine Learning*. IA Solver Blog.
<https://iasolver.es/6-librerias-de-python-para-machine-learning/>

2.3.1. FUNCIONAMENT D'UN DATASET COM A MATRIU.

- Tok, W. H. (s.f.). *Linear algebra for machine learning*. WholsTok Articles. <https://whoistok.com/articles/linear-algebra-for-machine-learning/>

2.3.2. LA NORMALITZACIÓ DE DADES COM A TRANSFORMACIÓ LINEAL

- Dhir, R. (2020, 24 de julio). *A practical walkthrough of min-max scaling*. Towards AI. <https://towardsai.net/p/machine-learning/a-practical-walkthrough-of-min-max-scaling>
- Wikipedia contributors. (2026, 8 de junio). *Feature scaling*. Wikipedia, The Free Encyclopedia. https://en.wikipedia.org/wiki/Feature_scaling

2.3.3.1 UTILITAT DELS VECTORS EN LA PRESA DE DECISIONS DE L'ALGORITME KNN

- Scikit-learn developers. (s.f.). *Nearest Neighbors – Mathematical Principles*. Scikit-learn documentation. <https://scikit-learn.org/stable/modules/neighbors.html>
- IBM. (s.f.). *¿Qué es el algoritmo KNN?*. IBM Think Topics. <https://www.ibm.com/es-es/think/topics/knn>

2.3.3.2 EL PRODUCTE ESCALAR COM A EINA DE SIMILITUD

- Abstract Algorithms. (s.f.). *Dot Product in Machine Learning*. Abstract Algorithms: The math behind the magic. <https://www.abstractalgorithms.dev/dot-product-in-machine-learning>
- APXML. (s.f.). *Similarity with Dot Products* (Chapter 6: Linear Algebra in ML). APXML Courses. <https://apxml.com/courses/linear-algebra-fundamentals-machine-learning/chapter-6-linear-algebra-in-ml/similarity-with-dot-products>
-